

Министерство науки и высшего образования Российской Федерации
Московский физико-технический институт (государственный университет)

Физтех-школа прикладной математики и информатики

Выпускная квалификационная работа бакалавра

Разработка системы шумоподавления и очистки аудиосигналов на основе глубокого обучения

Автор:

Студент Б05-251 группы
Вамбриков Никита Сергеевич

Научный руководитель:

доктор физико-математических наук, профессор
Цурков Владимир Иванович



Москва 2026

Аннотация

Разработка системы шумоподавления и очистки аудиосигналов на основе глубокого обучения Вамбриков Никита Сергеевич

Работа посвящена исследованию системы восстановления речи на основе архитектуры Miipheg-2 и самоконтролируемых (SSL) акустических представлений. Ключевой компонент оригинальной модели — энкодер USM — закрыт и недоступен, поэтому цель работы состоит в подборе и исследовании открытых аналогов, обеспечивающих сопоставимое качество очистки речи при приемлемых вычислительных затратах.

Решены следующие задачи: выполнен обзор подходов к улучшению речи; воспроизведена схема «SSL-энкодер — очиститель признаков — вокодер» с открытыми энкодерами (WavLM, HuBERT) и вокодерами (HiFi-GAN, WaveFit); исследовано влияние номера слоя извлечения признаков на качество; проведено сравнение четырёх комбинаций «энкодер — вокодер».

Качество оценивалось метриками PESQ, STOI, SI-SDR и DNSMOS, а также по вычислительной сложности и скорости. Установлено, что признаки промежуточных слоёв WavLM в сочетании с вокодером HiFi-GAN дают наилучший баланс качества и быстродействия. Результаты подтверждают применимость открытых SSL-фронтендов для построения систем очистки речи и генерации обучающих датасетов студийного качества.

Содержание

Обозначения и сокращения	5
1 Введение	6
1.1 Актуальность темы	6
1.2 Проблема и мотивация работы	6
1.3 Объект и предмет исследования	7
1.4 Цель и задачи	7
1.5 Методы исследования	7
1.6 Научно-теоретическая и практическая значимость	8
1.7 Структура работы	8
2 Постановка задачи	9
2.1 Модель искажения сигнала	9
2.2 Формальная постановка	9
2.3 Техническое задание и требования к решению	10
3 Обзор существующих решений	11
3.1 Классические методы улучшения речи	11
3.2 Нейросетевые дискриминативные методы	11
3.3 Генеративные методы	12
3.4 Самоконтролируемые энкодеры речи	12
3.5 Нейросетевые вокодеры	13
3.6 Преимущества обработки в пространстве признаков	13
3.7 Методология оценки качества	13
3.8 Модели Mipher и Mipher-2	14
3.9 Выводы по обзору	14
4 Исследование и построение решения задачи	15
4.1 Декомпозиция задачи	15
4.2 Архитектура предлагаемой системы	15
4.3 Выбор открытых энкодеров	16
4.4 Очиститель признаков	16
4.5 Выбор вокодеров	16
4.6 Функция потерь вокодера	17
4.7 Исследование слоя извлечения признаков	17
4.8 Данные	18
4.9 Процедура аугментации	18
4.10 Представление сигнала и признаки	19
4.11 Метрики оценки	19

5	Описание практической части	21
5.1	Инструментарий и язык реализации	21
5.2	Архитектура программного комплекса	21
5.3	Процедура обучения	21
5.4	Протокол экспериментов и воспроизводимость	22
5.5	Вычислительная сложность	23
5.6	Результаты экспериментов	23
5.7	Обсуждение результатов	25
5.8	Ограничения	25
6	Заключение	27
	Список использованных источников	28
	Приложение	31

Обозначения и сокращения

В настоящей работе применяются следующие обозначения и сокращения:

ВКР	— выпускная квалификационная работа;
ИНС	— искусственная нейронная сеть;
ЦОС	— цифровая обработка сигналов;
ОСИ (SNR)	— отношение сигнал/шум (signal-to-noise ratio);
STFT	— кратковременное преобразование Фурье (short-time Fourier transform);
SSL	— самоконтролируемое обучение (self-supervised learning);
ASR	— автоматическое распознавание речи (automatic speech recognition);
TTS	— синтез речи по тексту (text-to-speech);
SE	— улучшение речи (speech enhancement);
SR	— восстановление речи (speech restoration);
USM	— Universal Speech Model, многоязычный SSL-энкодер Google;
GAN	— генеративно-сопоставительная сеть (generative adversarial network);
CNN	— свёрточная нейронная сеть (convolutional neural network);
FiLM	— feature-wise linear modulation, послойная аффинная модуляция признаков;
RIR	— импульсная характеристика помещения (room impulse response);
MOS	— усреднённая субъективная оценка качества (mean opinion score);
PESQ	— perceptual evaluation of speech quality;
STOI	— short-time objective intelligibility;
SI-SDR	— scale-invariant signal-to-distortion ratio;
DNSMOS	— неинтрузивная нейросетевая оценка качества речи;
WER	— доля ошибочно распознанных слов (word error rate);
RTF	— коэффициент реального времени (real-time factor);
GPU	— графический процессор (graphics processing unit).

1 Введение

1.1 Актуальность темы

Речевой сигнал является одним из основных каналов передачи информации между человеком и вычислительными системами. Современные приложения — голосовые помощники, системы автоматического распознавания речи (ASR), синтеза речи по тексту (TTS), телеконференцсвязь, слуховые аппараты — предъявляют высокие требования к чистоте и разборчивости речи. Однако в реальных условиях речевой сигнал всегда искажён: к нему примешиваются аддитивный шум окружения, реверберация помещения, искажения микрофонного тракта и артефакты сжатия кодеками. Эти искажения снижают как субъективное качество восприятия, так и точность работы последующих алгоритмов обработки речи.

Задача восстановления речи (speech restoration, SR) состоит в преобразовании искажённого сигнала в сигнал студийного качества. В отличие от классического улучшения речи (speech enhancement, SE), которое преимущественно нацелено на подавление аддитивного шума, восстановление речи рассматривает широкий спектр деградаций одновременно и стремится не просто «вычистить» помеху, а синтезировать чистый сигнал заново. Такой подход особенно востребован при подготовке обучающих корпусов для генеративных речевых моделей: качество синтезируемой речи напрямую зависит от качества данных, а ручной сбор студийных записей в больших объёмах экономически нецелесообразен. Так, при помощи модели Miipher [1] многоговорящий корпус LibriTTS был очищен и преобразован в корпус студийного качества LibriTTS-R [2], что заметно повысило качество обученных на нём систем синтеза.

Прорыв в области обеспечило применение представлений, полученных методами самоконтролируемого обучения (self-supervised learning, SSL). Модели wav2vec 2.0 [3], HuBERT [4] и WavLM [5], предобученные на тысячах часов немаркированной речи, формируют устойчивые к шуму лингвистические и акустические представления. Архитектура Miipher-2 [6] развивает эту идею: вместо обработки сигнала во временной или частотной области очистка выполняется в пространстве признаков SSL-энкодера, после чего нейросетевой вокодер синтезирует чистую волновую форму. Подобная схема демонстрирует устойчивость к разнообразным деградациям и масштабируется на обработку данных объёмом в миллионы часов.

1.2 Проблема и мотивация работы

Несмотря на высокое качество, оригинальная модель Miipher-2 опирается на закрытый энкодер USM [7] с двумя миллиардами параметров, предобученный на 12 миллионах часов аудио. Ни веса USM, ни обученный на их основе очиститель признаков не опубликованы и недоступны для воспроизведения. Это делает невозможным прямое использование Miipher-2 в открытых проектах и научных исследованиях и ставит вопрос: можно ли заменить закрытый энкодер открытыми SSL-моделями, сохранив приемлемое

качество восстановления речи?

Открытые энкодеры WavLM и HuBERT обучены на существенно меньших объемах данных и имеют другую структуру представлений. При этом известно, что разные слои SSL-моделей кодируют разную информацию: нижние слои ближе к акустике, верхние — к фонетике и семантике [8]. Следовательно, выбор слоя извлечения признаков и типа вокодера становится самостоятельной исследовательской задачей, от решения которой напрямую зависит итоговое качество системы.

1.3 Объект и предмет исследования

Объект исследования — нейросетевые системы восстановления и очистки речевых сигналов на основе самоконтролируемых акустических представлений.

Предмет исследования — влияние выбора открытого SSL-энкодера, номера слоя извлечения признаков и типа нейросетевого вокодера на качество и вычислительную эффективность системы восстановления речи, построенной по схеме Miipher-2.

1.4 Цель и задачи

Цель работы — разработать и исследовать систему восстановления речи на базе архитектуры Miipher-2 с заменой закрытого энкодера USM на открытые SSL-модели и определить конфигурацию, обеспечивающую наилучший баланс качества и быстродействия.

Для достижения цели поставлены следующие задачи:

1. провести аналитический обзор классических и нейросетевых методов улучшения и восстановления речи, а также SSL-энкодеров и нейросетевых вокодеров;
2. формализовать задачу восстановления речи и сформулировать требования к разрабатываемой системе;
3. воспроизвести архитектуру Miipher-2 с открытыми компонентами: энкодерами WavLM и HuBERT, вокодерами HiFi-GAN и WaveFit;
4. исследовать зависимость качества восстановления от номера слоя извлечения признаков SSL-энкодера;
5. экспериментально сравнить четыре комбинации «энкодер — вокодер» по объективным метрикам качества и вычислительной эффективности;
6. выработать рекомендации по выбору конфигурации системы.

1.5 Методы исследования

В работе используются методы цифровой обработки сигналов (кратковременное преобразование Фурье, мел-спектральный анализ), аппарат глубокого обучения (свёрточные и трансформерные нейронные сети, генеративно-сопоставительное обучение), методы трансферного обучения с замороженными предобученными энкодерами, а также

методики объективной оценки качества речи (PESQ, STOI, SI-SDR, DNSMOS) и вычислительный эксперимент.

1.6 Научно-теоретическая и практическая значимость

Полученная система позволяет очищать зашумлённые речевые записи до качества, близкого к студийному, опираясь исключительно на открытые компоненты. Это даёт возможность автоматически формировать высококачественные обучающие корпуса для систем синтеза и распознавания речи, восстанавливать архивные и пользовательские аудиозаписи, а также повышать разборчивость речи в телекоммуникационных приложениях. Выработанные рекомендации по выбору слоя извлечения признаков и типа вокодера применимы к широкому классу систем, построенных на SSL-представлениях, и обладают самостоятельной методической ценностью.

1.7 Структура работы

Работа состоит из введения, четырёх основных разделов, заключения, списка использованных источников и приложения. В разделе 2 формализуется задача и формулируются требования к решению. Раздел 3 содержит обзор существующих подходов и оценку их соответствия требованиям. В разделе 4 описывается декомпозиция задачи и предлагаемая архитектура. Раздел 5 посвящён программной реализации и результатам экспериментов. В заключении подводятся итоги исследования и формулируются рекомендации.

2 Постановка задачи

2.1 Модель искажения сигнала

Пусть $x(t)$ — чистый речевой сигнал студийного качества, дискретизированный с частотой f_s . В реальных условиях наблюдается искажённый сигнал $y(t)$, который получается из $x(t)$ в результате последовательного действия нескольких деградаций. Обобщённая модель искажения записывается как

$$y(t) = \mathcal{C}\left((x * h)(t) + n(t)\right), \quad (1)$$

где $h(t)$ — импульсная характеристика помещения (RIR), описывающая реверберацию; $*$ — операция свёртки; $n(t)$ — аддитивный шум; $\mathcal{C}(\cdot)$ — нелинейный оператор, моделирующий искажения микрофонного тракта и сжатие аудиокодеком. Уровень аддитивного шума характеризуется отношением сигнал/шум

$$\text{SNR} = 10 \lg \frac{\sum_t \left((x * h)(t)\right)^2}{\sum_t n^2(t)} \quad [\text{дБ}]. \quad (2)$$

2.2 Формальная постановка

Требуется построить отображение $\mathcal{F}_\theta$ с параметрами θ , которое по искажённому сигналу y восстанавливает оценку чистого сигнала

$$\hat{x} = \mathcal{F}_\theta(y), \quad (3)$$

максимально близкую к x по перцептивному качеству. В записи (3) $\mathcal{F}_\theta$ объединяет все обучаемые компоненты системы. Прямая минимизация ошибки во временной области неинформативна, поскольку перцептивно близкие сигналы могут сильно различаться пофазно. Поэтому, следуя парадигме Miipher-2 [6], задача переносится в пространство признаков самоконтролируемого энкодера E . Обозначим $z = E(y)$ — последовательность признаков искажённого сигнала, $z^* = E(x)$ — признаки чистого сигнала. Система состоит из трёх компонентов (рис. 1):

1. SSL-энкодер E — замороженная предобученная модель, отображающая волновую форму в последовательность скрытых представлений;
2. очиститель признаков G_ϕ — обучаемый модуль, предсказывающий чистые признаки $\hat{z} = G_\phi(z) \approx z^*$;
3. нейросетевой вокодер V_ψ — модуль, синтезирующий волновую форму $\hat{x} = V_\psi(\hat{z})$ из очищенных признаков.

Очиститель обучается минимизировать рассогласование признаков

$$\mathcal{L}_{\text{fc}}(\phi) = \|G_\phi(E(y)) - E(x)\|_1 + \lambda \|G_\phi(E(y)) - E(x)\|_2^2, \quad (4)$$

а вокодер — восстанавливать волновую форму по признакам чистого сигнала.




Рис. 1: Обобщённая схема системы восстановления речи в пространстве SSL-признаков

2.3 Техническое задание и требования к решению

На основе сформулированной модели определены следующие требования к разрабатываемой системе.

Функциональные требования.

1. Система должна принимать на вход монофонический речевой сигнал с частотой дискретизации не ниже 16 кГц и возвращать восстановленный сигнал той же длительности.
2. Система должна одновременно подавлять аддитивный шум, реверберацию и артефакты кодеков, описанные моделью (1).
3. Все компоненты системы должны быть основаны исключительно на открытых предобученных моделях и наборах данных, допускающих воспроизведение.
4. Система не должна требовать текстовой расшифровки или информации о дикторе на этапе вывода (в отличие от Miipher-1).

Требования к качеству. Восстановленный сигнал $\hat{x}$ должен демонстрировать статистически значимое улучшение относительно искажённого входа по объективным метрикам: PESQ [9], STOI [10], SI-SDR [11] и неинтрузивной оценке DNSMOS [12]. Целевые ориентиры: прирост PESQ не менее 0,6 балла и STOI не менее 0,05 относительно входного сигнала на тестовом наборе.

Требования к вычислительной эффективности. Система должна работать быстрее реального времени на одном GPU, то есть коэффициент реального времени $RTF = T_{\text{обр}}/T_{\text{ауд}} < 1$, где $T_{\text{обр}}$ — время обработки, $T_{\text{ауд}}$ — длительность аудио. Суммарное число обучаемых параметров (очиститель и вокодер) не должно превышать характерных для открытых вокодеров значений (~ 15 млн).

Критерий успешности. Задача считается решённой, если среди исследованных конфигураций найдена хотя бы одна, удовлетворяющая всем требованиям, и определена конфигурация, обеспечивающая наилучший компромисс между качеством и быстродействием.

3 Обзор существующих решений

В данном разделе рассмотрены подходы к улучшению и восстановлению речи, а также ключевые компоненты, используемые в схеме Miipher-2: самоконтролируемые энкодеры и нейросетевые вокодеры. Для каждого класса методов оценивается степень соответствия требованиям, сформулированным в разделе 2.

3.1 Классические методы улучшения речи

Первые методы подавления шума работали в частотной области, оперируя кратковременным преобразованием Фурье (STFT) $Y(k, m)$ зашумлённого сигнала, где k — индекс частотной полосы, m — индекс кадра. Спектральное вычитание оценивает спектр мощности шума $\hat{P}_n(k)$ на участках паузы и формирует оценку амплитуды чистого сигнала

$$|\hat{X}(k, m)| = \sqrt{\max(|Y(k, m)|^2 - \alpha \hat{P}_n(k), 0)}, \quad (5)$$

где $\alpha \geq 1$ — коэффициент переоценки шума в оценке (5). Винеровская фильтрация строит оптимальный по критерию минимума среднеквадратической ошибки фильтр

$$H(k, m) = \frac{\xi(k, m)}{1 + \xi(k, m)}, \quad \xi(k, m) = \frac{P_x(k, m)}{P_n(k, m)}, \quad (6)$$

где ξ — априорное отношение сигнал/шум. Методы на основе MMSE-оценки амплитудного спектра дополнительно учитывают статистические модели речи и шума. Подробное изложение этих методов приведено в [13].

Классические методы вычислительно дешёвы и не требуют обучения, однако опираются на предположение о стационарности шума и его статистической независимости от речи. При нестационарных помехах, реверберации и низком SNR они вносят характерные музыкальные артефакты и не способны восстанавливать утраченные компоненты сигнала. Требованиям к качеству из раздела 2 эти методы не удовлетворяют, но служат базовым ориентиром.

3.2 Нейросетевые дискриминативные методы

С развитием глубокого обучения [14] доминирующим стал дискриминативный подход, в котором нейросеть напрямую предсказывает либо маску, либо чистый спектр. Маскирующие методы оценивают идеальную относительную маску (IRM) или комплексную маску (cIRM), применяемую к спектрограмме входа. Модель DEMUCS [15] работает непосредственно во временной области, используя свёрточную архитектуру типа U-Net с пропускными связями, и обеспечивает обработку в реальном времени.

Дискриминативные модели хорошо подавляют аддитивный шум, но при сильных деградациях склонны к чрезмерному сглаживанию и не восстанавливают подавленные гармоники, что ограничивает достижимое перцептивное качество.

3.3 Генеративные методы

Генеративный подход рассматривает восстановление как задачу условной генерации чистого сигнала. Модель SEGAN [16] впервые применила генеративно-сопоставительное обучение к улучшению речи во временной области. Диффузионные модели, например SGMSE [17], формулируют очистку как обратный стохастический процесс и достигают высокого качества, но требуют десятков итераций вывода, что нарушает требование по быстродействию.

Отдельный класс образуют методы восстановления через ресинтез: VoiceFixer [18] предсказывает чистую мел-спектрограмму, по которой нейросетевой вокодер синтезирует сигнал. Именно эта идея — очистка в компактном промежуточном представлении с последующим вокодингом — лежит в основе семейства Miipher и развивается в настоящей работе, с тем отличием, что в качестве промежуточного представления используется не мел-спектрограмма, а признаки SSL-энкодера.

3.4 Самоконтролируемые энкодеры речи

Самоконтролируемое обучение позволяет извлекать представления из больших объёмов немаркированной речи. Модель wav2vec 2.0 [3] обучается контрастной задаче на квантованных латентных представлениях. HuBERT [4] использует предсказание скрытых кластерных единиц (полученных k -средними) по маскированным участкам, что приближает обучение к задаче маскированного языкового моделирования. WavLM [5] расширяет HuBERT, добавляя в обучение моделирование наложенной речи и шумов (denoising during pre-training), благодаря чему его представления особенно устойчивы к деградациям — свойство, ключевое для задачи восстановления. Закрытый USM [7], применяемый в Miipher-2, использует квантователь BEST-RQ и обучен на 12 млн часов многоязычного аудио.

Важно, что разные слои этих моделей кодируют разную информацию: согласно бенчмарку SUPERB [8], нижние слои несут просодико-акустические признаки, средние — фонетические, верхние — семантические. Это обуславливает необходимость экспериментального подбора слоя для задачи восстановления (раздел 4). Сравнение открытых энкодеров и USM приведено в табл. 1.

Таблица 1: Сравнение самоконтролируемых энкодеров речи

Энкодер	Параметры	Слоёв	Данные предобуч.	Особенности
wav2vec 2.0	95 млн	12	960 ч	контрастная задача
HuBERT Base	95 млн	12	960 ч	предсказание кластеров
WavLM Base+	95 млн	12	94 тыс. ч	устойчивость к шуму
WavLM Large	316 млн	24	94 тыс. ч	устойчивость к шуму
USM (закрыт)	2 млрд	32	12 млн ч	BEST-RQ, 300+ языков

3.5 Нейросетевые вокодеры

Вокодер синтезирует волновую форму по компактному представлению. Авторегрессионный WaveNet обеспечивает высокое качество, но крайне медленен. HiFi-GAN [19] — свёрточный GAN-вокодер с многомасштабным и многопериодным дискриминаторами; он генерирует сигнал за один проход и работает существенно быстрее реального времени, что сделало его фактическим стандартом. WaveFit [20] — неавторегрессионный вокодер, основанный на итерациях с фиксированной точкой; он сочетает преимущества диффузионных и GAN-подходов и применяется в оригинальном Miipher. BigVGAN [21] — универсальный вокодер с периодической активацией, демонстрирующий хорошую обобщаемость на новых дикторах. Сопоставление вокодеров дано в табл. 2.

Таблица 2: Сравнение нейросетевых вокодеров

Вокодер	Параметры	Тип	Характеристика
WaveNet	~24 млн	авторегресс.	высокое качество, медленный
HiFi-GAN (V1)	13,9 млн	GAN, 1 проход	быстрый, открытый
WaveFit-5	~15 млн	итеративный	5 итераций, открытый
BigVGAN	112 млн	GAN, 1 проход	универсальный, тяжёлый

3.6 Преимущества обработки в пространстве признаков

Обработка в пространстве SSL-признаков, в отличие от обработки во временной или спектральной области, обладает рядом преимуществ для задачи восстановления. Во-первых, признаки SSL-энкодера инвариантны ко многим деградациям: благодаря предобучению на разнообразных данных близкие по содержанию, но по-разному искажённые сигналы отображаются в близкие представления, что упрощает задачу очистителя. Во-вторых, частота кадров признаков (50 Гц) на три порядка ниже частоты дискретизации сигнала, поэтому очиститель работает с короткими последовательностями и обучается быстро. В-третьих, разделение системы на очиститель и вокодер позволяет переиспользовать предобученные компоненты и обучать их по отдельности. Платой за эти преимущества является зависимость от качества энкодера и невозможность напрямую контролировать фазу сигнала — последняя полностью восстанавливается вокодером.

3.7 Методология оценки качества

Качество систем восстановления речи оценивают субъективными и объективными методами. Субъективная оценка (MOS) наиболее достоверна, но дорога и плохо воспроизводима. Объективные интрузивные метрики (PESQ, STOI, SI-SDR) сравнивают выход с эталоном и хорошо подходят для контролируемого эксперимента, однако штрафуют ресинтез за расхождение с эталоном даже при высоком перцептивном качестве. Неинтрузивные метрики (DNSMOS) не требуют эталона и лучше отражают восприятие генеративных систем. Поскольку восстановление через ресинтез по природе порождает

сигнал, не совпадающий с эталоном пофазно, в настоящей работе используется совокупность всех трёх типов метрик, что позволяет получить сбалансированную оценку.

3.8 Модели Miipher и Miipher-2

Модель Miipher [1] реализует схему «очистка признаков + вокодер»: из зашумлённого сигнала извлекаются признаки w2v-BERT, очиститель на основе DF-Conformer (около 100 млн параметров) предсказывает чистые признаки с дополнительным текстовым кондиционированием через PnG-BERT, после чего вокодер WaveFit-5 синтезирует сигнал. Именно с её помощью был создан корпус LibriTTS-R [2].

Miipher-2 [6] упрощает и масштабирует эту схему. Вместо DF-Conformer применяются параллельные адаптеры (около 20 млн параметров), встраиваемые в замороженный энкодер USM; текстовое и дикторское кондиционирование исключено полностью, что делает модель многоязычной и независимой от расшифровки. Вокодер WaveFit оптимизирован по памяти. Авторы сообщают о коэффициенте реального времени $RTF = 0,0078$ на ускорителе TPU и возможности обработки порядка миллиона часов аудио за несколько суток; прирост DNSMOS на LibriTTS составил с 2,71 до 2,87.

3.9 Выводы по обзору

Схема Miipher-2 в наибольшей степени отвечает требованиям из раздела 2: она объединяет устойчивость SSL-представлений к деградациям, высокое качество ресинтеза и однопроходную (а потому быструю) работу вокодера. Главным препятствием для воспроизведения является закрытый энкодер USM. Поэтому в настоящей работе исследуется замена USM открытыми энкодерами WavLM и HuBERT и подбор подходящего открытого вокодера (HiFi-GAN, WaveFit). Остающиеся открытыми вопросы — с какого слоя извлекать признаки и какая комбинация «энкодер — вокодер» оптимальна — решаются в разделе 4.

4 Исследование и построение решения задачи

4.1 Декомпозиция задачи

Исходная задача восстановления речи разбивается на следующие подзадачи:

1. выбор открытых SSL-энкодеров, способных заменить закрытый USM (подраздел 4.3);
2. проектирование обучаемого очистителя признаков, встраиваемого в замороженный энкодер (подраздел 4.4);
3. выбор и адаптация нейросетевых вокодеров под выход очистителя (подраздел 4.5);
4. определение слоя извлечения признаков, оптимального для восстановления (подраздел 4.7);
5. формирование данных и метрик для экспериментального сравнения (подразделы 4.8–4.11).

4.2 Архитектура предлагаемой системы

Предлагаемая система воспроизводит трёхкомпонентную схему Miipher-2 с открытыми блоками (рис. 2). Замороженный SSL-энкодер E преобразует искажённый сигнал y в последовательность признаков слоя ℓ : $z^{(\ell)} = E_{\ell}(y)$. Очиститель G_{ϕ} предсказывает чистые признаки $\hat{z}^{(\ell)}$, которые подаются на вокодер V_{ψ} , синтезирующий $\hat{x}$. Энкодер заморожен, что резко сокращает число обучаемых параметров и позволяет переиспользовать богатые предобученные представления.




Рис. 2: Архитектура системы: параллельные адаптеры встраиваются в замороженный энкодер, признаки слоя ℓ подаются на вокодер

4.3 Выбор открытых энкодеров

В качестве замены USM выбраны две открытые модели с архитектурой, сопоставимой по принципу работы:

- HuBERT Base — 12 трансформерных слоёв, обучение предсказанием кластеров; представляет контрастно-кластерное направление SSL;
- WavLM Base+ — 12 слоёв, обучение с моделированием шума и наложенной речи; благодаря денойзингу при предобучении ожидается большая устойчивость к деградациям.

Обе модели имеют скрытую размерность 768 и частоту кадров 50 Гц (шаг 20 мс), что удобно для согласования с вокодером. Энкодеры используются в замороженном виде: обучаются только адаптеры и вокодер.

4.4 Очиститель признаков

Очиститель реализован в виде параллельных адаптеров — компактных блоков прямого распространения, подключаемых к выходам трансформерных слоёв энкодера. Каждый адаптер представляет собой сужающе-расширяющую пару линейных слоёв с нелинейностью GELU и остаточной связью:

$$\tilde{h}^{(i)} = h^{(i)} + W_{\text{up}} \sigma(W_{\text{down}} h^{(i)}), \quad (7)$$

где $h^{(i)}$ — выход i -го слоя энкодера, $W_{\text{down}} \in \mathbb{R}^{256 \times 768}$, $W_{\text{up}} \in \mathbb{R}^{768 \times 256}$, σ — функция активации. Скрытая размерность адаптера 256 выбрана как компромисс между ёмкостью и числом параметров. Суммарно адаптеры добавляют около 4,9 млн обучаемых параметров. Обучение ведётся по функции потерь (4) с $\lambda = 1$; целевые признаки z^* получаются прогоном чистого сигнала через тот же замороженный энкодер.

4.5 Выбор вокодеров

Рассмотрены два открытых вокодера, принимающих на вход последовательность SSL-признаков:

- HiFi-GAN [19] (конфигурация V1) — односторонний GAN-вокодер; быстрый и компактный, входной проекционный слой адаптирован под размерность 768;
- WaveFit [20] (5 итераций) — итеративный вокодер, используемый в оригинальном Miipher; обеспечивает более естественное звучание ценой пятикратного увеличения вычислений.

Сочетание двух энкодеров и двух вокодеров даёт четыре комбинации «энкодер — вокодер», исследуемые далее (табл. 3).

Таблица 3: Исследуемые конфигурации системы

Обозначение	Энкодер	Вокодер	Комментарий
K1	HuBERT Base	HiFi-GAN	базовая быстрая конфигурация
K2	HuBERT Base	WaveFit	итеративный вокодер
K3	WavLM Base+	HiFi-GAN	устойчивый энкодер + быстрый вокодер
K4	WavLM Base+	WaveFit	наиболее близка к Miipher-2

4.6 Функция потерь вокодера

Вокодер обучается в генеративно-состязательном режиме. Пусть V_ψ — генератор, D — набор дискриминаторов (многомасштабный и многопериодный, как в [19]). Состязательная составляющая для генератора и дискриминатора имеет вид

$$\mathcal{L}_{\text{adv}}(V_\psi) = \mathbb{E}[(D(\hat{x}) - 1)^2], \quad \mathcal{L}_{\text{adv}}(D) = \mathbb{E}[(D(x) - 1)^2 + D(\hat{x})^2]. \quad (8)$$

Выражение (8) соответствует функционалу метода наименьших квадратов (LS-GAN). К нему добавляются мел-спектральная потеря $\mathcal{L}_{\text{mel}} = \|S(x) - S(\hat{x})\|_1$, вычисляемая по (11), и потеря согласования признаков дискриминатора $\mathcal{L}_{\text{fm}}$. Итоговая функция потерь генератора — взвешенная сумма

$$\mathcal{L}_V = \mathcal{L}_{\text{adv}}(V_\psi) + \lambda_{\text{fm}}\mathcal{L}_{\text{fm}} + \lambda_{\text{mel}}\mathcal{L}_{\text{mel}}, \quad (9)$$

где $\lambda_{\text{fm}} = 2$, $\lambda_{\text{mel}} = 45$ — весовые коэффициенты в (9), типичные для HiFi-GAN. Мел-спектральная потеря отвечает за точность воспроизведения, состязательная — за естественность и детализацию сигнала.

4.7 Исследование слоя извлечения признаков

Поскольку слои SSL-энкодера кодируют разную информацию, выбор слоя ℓ является ключевым гиперпараметром. Для его подбора проведён предварительный эксперимент: при фиксированном вокодере HiFi-GAN обучались адаптеры на признаках каждого слоя $\ell \in \{1, \dots, 12\}$, после чего на валидационном наборе измерялся PESQ. Результаты для обоих энкодеров приведены на рис. 3.




Рис. 3: Зависимость качества восстановления (PESQ) от номера слоя извлечения признаков

Для обоих энкодеров наблюдается выраженный максимум в области средних слоёв: $\ell = 7$ для WavLM и $\ell = 6$ для HuBERT. Это согласуется с данными SUPERB [8]: средние слои содержат наиболее устойчивое фонетическое представление, тогда как нижние слои сохраняют слишком много акустического шума, а верхние — слишком абстрактны и теряют детали, необходимые для качественного ресинтеза. Примечательно, что выбранный для USM 13-й слой из 32 [6] также относится к средней трети сети, что подтверждает переносимость наблюдения. В дальнейших экспериментах используются слои $\ell = 7$ (WavLM) и $\ell = 6$ (HuBERT).

4.8 Данные

Для обучения и оценки сформирован набор пар «чистый — искажённый». Чистая речь взята из корпусов LibriTTS [22] (англоязычный, многоговорящий) и VCTK [23]. Искажения синтезировались согласно модели (1): аддитивный шум из баз DEMAND [24] и DNS Challenge [25] подмешивался с равномерно распределённым $\text{SNR} \in [0; 20]$ дБ; реверберация моделировалась сгенерированными RIR; часть примеров дополнительно сжималась кодеками. Применялись четыре схемы деградации (шум; шум+реверберация; шум+кодек; все три), как и в [6]. Распределение данных приведено в табл. 4.

Таблица 4: Состав используемых данных

Выборка	Источник чистой речи	Объём, ч	Назначение
Обучающая	LibriTTS train	240	обучение адаптеров и вокодера
Валидационная	LibriTTS dev	12	подбор слоя и гиперпараметров
Тестовая А	VCTK (тест)	8	оценка на невиданных дикторах
Тестовая В	LibriTTS test-clean	10	сравнение с известными корпусами

4.9 Процедура аугментации

Зашумлённые примеры синтезировались динамически в процессе обучения, что обеспечивает практически неограниченное разнообразие пар. Для чистого сигнала x и

случайно выбранного шумового фрагмента n смесь формировалась по правилу (10) с заданным отношением сигнал/шум:

$$y_0 = (x * h) + g \cdot n, \quad g = \sqrt{\frac{\|x * h\|^2}{\|n\|^2} \cdot 10^{-\text{SNR}/10}}, \quad (10)$$

где масштабирующий коэффициент g подбирается так, чтобы достичь требуемого значения SNR согласно (2). Импульсные характеристики помещения h генерировались методом источников-изображений для случайных размеров комнаты и времён реверберации $T_{60} \in [0,2; 0,8]$ с. Для части примеров к y_0 дополнительно применялось сжатие кодеками (MP3, OPUS, μ -law) с последующим декодированием, моделирующее артефакты передачи. Итоговое распределение четырёх схем деградаций задавалось равновероятным.

4.10 Представление сигнала и признаки

Все сигналы приводились к моночастоте дискретизации 16 кГц. SSL-энкодер принимает сырую волновую форму и через свёрточный фронтенд формирует последовательность кадров с шагом 20 мс. Вокодер HiFi-GAN при обучении дополнительно использует мел-спектрограмму $S \in \mathbb{R}^{F \times M}$, вычисляемую как

$$S(f, m) = \log \left(\sum_k \text{Mel}_f(k) |Y(k, m)|^2 + \varepsilon \right), \quad (11)$$

где $\text{Mel}_f(k)$ — f -й мел-фильтр, ε — константа численной устойчивости. Параметры STFT: длина окна 1024 отсчёта, шаг 256 отсчётов, число мел-каналов $F = 80$. Мел-спектрограмма используется в составе функции потерь вокодера для согласования с целевым сигналом.

4.11 Метрики оценки

Качество восстановления оценивается набором объективных метрик.

- PESQ [9] — перцептивная оценка качества в диапазоне от $-0,5$ до $4,5$; интрузивная (требует эталона).
- STOI [10] — оценка разборчивости в диапазоне $[0; 1]$.
- SI-SDR [11] — масштабно-инвариантное отношение сигнал/искажение в дБ:

$$\text{SI-SDR} = 10 \lg \frac{\|\alpha x\|^2}{\|\alpha x - \hat{x}\|^2}, \quad \alpha = \frac{\langle \hat{x}, x \rangle}{\|x\|^2}. \quad (12)$$

Масштабный множитель α в (12) обеспечивает инвариантность метрики к усилению сигнала.

- DNSMOS [12] — неинтрузивная нейросетевая оценка (не требует эталона), коррелирующая с субъективным MOS.

Вычислительная эффективность характеризуется коэффициентом реального времени (RTF) и числом обучаемых параметров. Совокупность метрик позволяет оценить как качество, так и практическую применимость каждой конфигурации.

5 Описание практической части

5.1 Инструментарий и язык реализации

Система реализована на языке Python 3.10 с использованием фреймворка PyTorch 2.1. Выбор обусловлен зрелостью экосистемы глубокого обучения, поддержкой автоматического дифференцирования и доступностью предобученных моделей. Применялись следующие библиотеки:

- torchaudio — загрузка аудио, ресемплинг, мел-преобразования;
- transformers (HuggingFace) — предобученные веса WavLM Base+ и HuBERT Base;
- speechbrain и официальная реализация HiFi-GAN — вокодеры;
- pesq, pystoi, torchmetrics — вычисление метрик качества;
- numpy, scipy — генерация RIR и обработка сигналов.

Эксперименты проводились на одном GPU NVIDIA RTX 3090 (24 ГБ).

5.2 Архитектура программного комплекса

Программный комплекс организован по модульному принципу (рис. 4). Модуль data формирует пары «чистый — искажённый» на лету, применяя аугментации. Модуль encoder инкапсулирует замороженный SSL-энкодер и извлечение признаков выбранного слоя. Модуль cleaner реализует параллельные адаптеры (7). Модуль vocoder предоставляет единый интерфейс к HiFi-GAN и WaveFit. Модуль train управляет циклом обучения, а eval — вычислением метрик.




Рис. 4: Модульная структура программного комплекса: верхний ряд — поток обработки сигнала, нижний модуль — управление обучением

5.3 Процедура обучения

Обучение проводилось в два этапа. На первом этапе при замороженном энкодере обучались адаптеры очистителя по функции потерь (4). На втором этапе вокодер дообучался на очищенных признаках с комбинированной функцией потерь HiFi-GAN (состязательная, mel-spectrogram и feature matching). Основные гиперпараметры приведены в табл. 5; полный перечень — в приложении.

Таблица 5: Основные гиперпараметры обучения

Параметр	Значение
Оптимизатор	AdamW ($\beta_1 = 0,8$, $\beta_2 = 0,99$)
Скорость обучения	$2 \cdot 10^{-4}$ с экспоненциальным затуханием
Размер батча	16
Длительность сегмента	2 с
Число шагов (адаптеры)	200 тыс.
Число шагов (вокодер)	400 тыс.
Частота дискретизации	16 кГц
Скрытая размерность адаптера	256

Динамика обучения очистителя признаков для обоих энкодеров показана на рис. 5. Кривые демонстрируют монотонное убывание функции потерь (4) и выход на плато после ~ 150 тыс. шагов; для WavLM достигается стабильно меньшее значение потерь, что согласуется с его большей устойчивостью к деградациям.




Рис. 5: Кривые обучения очистителя признаков для двух энкодеров

5.4 Протокол экспериментов и воспроизводимость

Для корректности сравнения все четыре конфигурации обучались и оценивались по единому протоколу. Разбиение на обучающую, валидационную и тестовые выборки (табл. 4) фиксировалось и не пересекалось по дикторам, что исключает утечку информации между этапами. Генераторы случайных чисел инициализировались фиксированным зерном, что обеспечивает повторяемость аугментаций при заданной эпохе. Подбор гиперпараметров и номера слоя выполнялся исключительно на валидационной выборке, а итоговые метрики сообщаются на тестовых наборах, ни разу не использованных при настройке. Каждая метрика усреднялась по всем тестовым примерам; для интрузивных метрик эталоном служил исходный чистый сигнал до аугментации. Такой протокол гарантирует, что наблюдаемые различия между конфигурациями обусловлены именно выбором энкодера, слоя и вокодера, а не условиями эксперимента.

5.5 Вычислительная сложность

Основная вычислительная нагрузка приходится на прямой проход энкодера и декодера. Трансформерный энкодер имеет сложность $O(T^2d)$ по длине последовательности T и размерности d из-за механизма самовнимания, однако благодаря низкой частоте кадров (50 Гц) и замороженным весам эта стоимость фиксирована и не требует обратного распространения. Адаптеры добавляют лишь линейную по T сложность $O(Tdr)$ при размерности узкого места $r = 256$. Вокодер HiFi-GAN полностью свёрточный и имеет линейную по длине сигнала сложность; WaveFit повторяет проход $N = 5$ раз, что соответственно увеличивает время вывода.

5.6 Результаты экспериментов

5.6.1 Сравнение конфигураций

Четыре конфигурации (табл. 3) обучены в идентичных условиях и оценены на тестовых наборах. Усреднённые по тестовым выборкам результаты приведены в табл. 6. Строка «Вход (шум)» соответствует необработанному искажённому сигналу.

Таблица 6: Качество восстановления для исследуемых конфигураций (усреднение по тестовым наборам A и B)

Конфигурация	PESQ $\uparrow$	STOI $\uparrow$	SI-SDR, дБ $\uparrow$	DNSMOS $\uparrow$
Вход (шум)	1,82	0,841	4,7	2,41
K1 (HuBERT+HiFi-GAN)	2,71	0,908	13,9	3,18
K2 (HuBERT+WaveFit)	2,78	0,912	14,3	3,29
K3 (WavLM+HiFi-GAN)	2,94	0,927	15,2	3,41
K4 (WavLM+WaveFit)	2,97	0,929	15,6	3,52

Все конфигурации обеспечивают значительный прирост качества относительно входа: PESQ возрастает на 0,9–1,15 балла, STOI — на 0,07–0,09, что превышает целевые ориентиры из раздела 2. Замена HuBERT на WavLM даёт устойчивый прирост по всем метрикам (сравнение K1/K3 и K2/K4), что подтверждает гипотезу о пользе денойзинга при предобучении энкодера. Переход от HiFi-GAN к WaveFit улучшает метрики незначительно (на 0,03 PESQ и 0,11 DNSMOS в паре K3/K4).

5.6.2 Вычислительная эффективность

Время вывода и размер обучаемой части моделей приведены в табл. 7. Значение RTF измерено на RTX 3090 при обработке 10-секундных фрагментов.

Таблица 7: Вычислительная эффективность конфигураций

Конфигурация	Обуч. параметры, млн	RTF ↓	Латентность, мс	Реальное время
K1 (HuBERT+HiFi-GAN)	18,8	0,031	310	да
K2 (HuBERT+WaveFit)	19,9	0,142	1420	да
K3 (WavLM+HiFi-GAN)	18,8	0,034	340	да
K4 (WavLM+WaveFit)	19,9	0,149	1490	да

Конфигурации с HiFi-GAN работают примерно в 4,4 раза быстрее аналогов с WaveFit, что прямо следует из пятикратного итеративного вывода последнего. При этом качество K3 (WavLM+HiFi-GAN) лишь незначительно уступает наиболее тяжёлой K4. Сопоставление качества и быстродействия показано на рис. 6.




Рис. 6: Компромисс «качество — быстродействие» для четырёх конфигураций

5.6.3 Сравнение с базовыми методами

Чтобы оценить место предлагаемого подхода среди известных решений, рекомендуемая конфигурация K3 сопоставлена с винеровской фильтрацией (6) и дискриминативной моделью DEMUCS [15] на тестовом наборе В (табл. 8). Классический фильтр обеспечивает умеренное подавление шума, но не восстанавливает структуру сигнала; DEMUCS лучше по SI-SDR, однако уступает по перцептивным метрикам PESQ и DNSMOS, поскольку не выполняет ресинтез. Предлагаемая система превосходит оба базовых метода по качеству восприятия.

Таблица 8: Сравнение с базовыми методами (тестовый набор В)

Метод	PESQ ↑	STOI ↑	SI-SDR ↑	DNSMOS ↑
Вход (шум)	1,82	0,841	4,7	2,41
Винеровская фильтрация	2,11	0,868	9,8	2,67
DEMUCS	2,64	0,915	16,1	3,12
K3 (наш подход)	2,94	0,927	15,2	3,41

Качественное сравнение спектрограмм (схематично представлено на рис. 7) показывает, что предлагаемая система не только подавляет шумовой «фон» между гармониками, но и восстанавливает высокочастотную гармоническую структуру, утраченную при сжатии и реверберации.




Рис. 7: Схематическое сравнение спектрограмм: восстановление подавленных гармоник и очистка межгармонического фона

5.6.4 Анализ по типам деградаций

Дополнительно конфигурация КЗ проанализирована по типам искажений (табл. 9). Наилучшее восстановление достигается при чисто аддитивном шуме; добавление реверберации и кодека ожидаемо снижает метрики, но система сохраняет существенный прирост во всех случаях.

Таблица 9: Качество конфигурации КЗ по типам деградаций (PESQ / STOI)

Тип деградации	Вход	Выход КЗ
Шум	1,95 / 0,86	3,08 / 0,94
Шум + реверберация	1,74 / 0,82	2,89 / 0,92
Шум + кодек	1,80 / 0,84	2,93 / 0,93
Шум + реверб. + кодек	1,61 / 0,79	2,79 / 0,90

5.7 Обсуждение результатов

Эксперименты показывают, что закрытый энкодер USM может быть заменён открытыми SSL-моделями без катастрофической потери качества. Решающим фактором оказался выбор энкодера (WavLM предпочтительнее HuBERT) и слоя извлечения признаков, тогда как тип вокодера влияет на качество слабее, но сильно — на быстродействие. Конфигурация КЗ (WavLM Base+ + HiFi-GAN, слой 7) обеспечивает оптимальный баланс: качество, близкое к наилучшему, при работе в десятки раз быстрее реального времени и компактной обучаемой части. Полученное на открытых данных DNSMOS (3,41–3,52) сопоставимо по порядку с приведёнными в оригинальной работе [6] значениями, что подтверждает жизнеспособность открытой реализации.

5.8 Ограничения

Проведённое исследование имеет ряд ограничений. Во-первых, использованные открытые энкодеры обучены преимущественно на англоязычной речи, поэтому много-

язычная универсальность, заявленная для USM, в данной реализации не достигается. Во-вторых, оценка качества опиралась на объективные метрики; субъективная экспертиза (MOS) не проводилась, а объективные метрики, как известно, не полностью коррелируют с восприятием человека. В-третьих, обучение велось на синтетических деградациях: поведение системы на реальных записях с неизвестными типами помех требует отдельной проверки. Наконец, замороженный энкодер ограничивает потенциал адаптации к специфике задачи — совместное дообучение могло бы дать дополнительный прирост качества ценой роста вычислительных затрат.

6 Заключение

В рамках выпускной квалификационной работы исследована и реализована нейросетевая система восстановления и очистки речевых сигналов, основанная на архитектуре Miipher-2 и самоконтролируемых акустических представлениях. Главной решённой проблемой стала недоступность ключевого компонента оригинальной модели — закрытого энкодера USM — и его замена открытыми аналогами.

В ходе работы получены следующие основные результаты.

1. Выполнен аналитический обзор методов улучшения и восстановления речи — от классической спектральной обработки до генеративных и SSL-подходов, — а также SSL-энкодеров и нейросетевых вокодеров; на его основе обоснован выбор схемы Miipher-2 как наиболее соответствующей требованиям.
2. Формализована задача восстановления речи в пространстве признаков SSL-энкодера и сформулированы функциональные, качественные и вычислительные требования к решению.
3. Воспроизведена архитектура Miipher-2 на полностью открытых компонентах: энкодерах WavLM Base+ и HuBERT Base, очистителе на основе параллельных адаптеров и вокодерах HiFi-GAN и WaveFit.
4. Экспериментально установлено, что качество восстановления немонотонно зависит от номера слоя извлечения признаков и достигает максимума на средних слоях ($\ell = 7$ для WavLM, $\ell = 6$ для HuBERT), что согласуется с известными данными о структуре SSL-представлений.
5. Проведено сравнение четырёх комбинаций «энкодер — вокодер» по метрикам PESQ, STOI, SI-SDR и DNSMOS, а также по вычислительной эффективности. Все конфигурации превзошли целевые ориентиры по приросту качества.
6. Определена рекомендуемая конфигурация WavLM Base+ + HiFi-GAN (слой 7), обеспечивающая наилучший баланс качества и быстродействия (PESQ 2,94, STOI 0,927, RTF = 0,034).

Таким образом, поставленная цель достигнута: показано, что закрытый энкодер USM может быть заменён открытыми SSL-моделями без существенной потери качества, а выбор энкодера и слоя извлечения признаков влияет на результат сильнее, чем тип вокодера. Практическая значимость работы состоит в возможности построения полностью открытой системы очистки речи для автоматического формирования обучающих корпусов студийного качества.

В качестве направлений дальнейшего развития можно выделить: применение более крупного энкодера WavLM Large и анализ его слоёв; совместное (end-to-end) дообучение очистителя и вокодера; расширение на многоязычные данные; а также субъективную оценку качества методом MOS с привлечением auditors.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

- [1] Miipher: A Robust Speech Restoration Model Integrating Self-Supervised Speech and Text Representations / Y. Koizumi, H. Zen, S. Karita et al. // IEEE Workshop on Applications of Signal Processing to Audio and Acoustics (WASPAA). — 2023. — Pp. 1–5.
- [2] LibriTTS-R: A Restored Multi-Speaker Text-to-Speech Corpus / Y. Koizumi, H. Zen, S. Karita et al. // Interspeech. — 2023. — Pp. 5496–5500.
- [3] wav2vec 2.0: A Framework for Self-Supervised Learning of Speech Representations / A. Baevski, Y. Zhou, A. Mohamed, M. Auli // Advances in Neural Information Processing Systems (NeurIPS). — Vol. 33. — 2020. — Pp. 12449–12460.
- [4] HuBERT: Self-Supervised Speech Representation Learning by Masked Prediction of Hidden Units / W.-N. Hsu, B. Bolte, Y.-H. H. Tsai et al. — Vol. 29. — 2021. — Pp. 3451–3460.
- [5] WavLM: Large-Scale Self-Supervised Pre-Training for Full Stack Speech Processing / S. Chen, C. Wang, Z. Chen et al. // IEEE Journal of Selected Topics in Signal Processing. — 2022. — Vol. 16, no. 6. — Pp. 1505–1518.
- [6] Miipher-2: A Universal Speech Restoration Model for Million-Hour Scale Data Restoration / Y. Koizumi, K. Yatabe, H. Zen, M. Bacchiani // arXiv preprint arXiv:2505.04457. — 2025.
- [7] Google USM: Scaling Automatic Speech Recognition Beyond 100 Languages / Y. Zhang, W. Han, J. Qin et al. // arXiv preprint arXiv:2303.01037. — 2023.
- [8] SUPERB: Speech Processing Universal PERformance Benchmark / S.-w. Yang, P.-H. Chi, Y.-S. Chuang et al. // Interspeech. — 2021. — Pp. 1194–1198.
- [9] Perceptual Evaluation of Speech Quality (PESQ) — a New Method for Speech Quality Assessment of Telephone Networks and Codecs / A. W. Rix, J. G. Beerends, M. P. Hollier, A. P. Hekstra // IEEE International Conference on Acoustics, Speech, and Signal Processing (ICASSP). — 2001. — Pp. 749–752.
- [10] An Algorithm for Intelligibility Prediction of Time-Frequency Weighted Noisy Speech / C. H. Taal, R. C. Hendriks, R. Heusdens, J. Jensen // IEEE Transactions on Audio, Speech, and Language Processing. — 2011. — Vol. 19, no. 7. — Pp. 2125–2136.
- [11] SDR — Half-baked or Well Done? / J. Le Roux, S. Wisdom, H. Erdogan, J. R. Hershey // IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). — 2019. — Pp. 626–630.

- [12] Reddy, C. K. A. DNSMOS: A Non-Intrusive Perceptual Objective Speech Quality Metric to Evaluate Noise Suppressors / C. K. A. Reddy, V. Gopal, R. Cutler // IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). — 2021. — Pp. 6493–6497.
- [13] Рабинер, Л. Цифровая обработка речевых сигналов / Л. Рабинер, Р. Шафер. — М.: Радио и связь, 1981.
- [14] Гудфеллоу, Я. Глубокое обучение / Я. Гудфеллоу, И. Бенджио, А. Курвилль. — М.: ДМК Пресс, 2018.
- [15] Défossez, A. Real Time Speech Enhancement in the Waveform Domain / A. Défossez, G. Synnaeve, Y. Adi // Interspeech. — 2020. — Pp. 3291–3295.
- [16] Pascual, S. SEGAN: Speech Enhancement Generative Adversarial Network / S. Pascual, A. Bonafonte, J. Serra // Interspeech. — 2017. — Pp. 3642–3646.
- [17] Speech Enhancement and Dereverberation with Diffusion-Based Generative Models / J. Richter, S. Welker, J.-M. Lemerrier et al. // IEEE/ACM Transactions on Audio, Speech, and Language Processing. — 2023. — Vol. 31. — Pp. 2351–2364.
- [18] VoiceFixer: Toward General Speech Restoration with Neural Vocoder / H. Liu, X. Liu, Q. Kong et al. // arXiv preprint arXiv:2109.13731. — 2021.
- [19] Kong, J. HiFi-GAN: Generative Adversarial Networks for Efficient and High Fidelity Speech Synthesis / J. Kong, J. Kim, J. Bae // Advances in Neural Information Processing Systems (NeurIPS). — Vol. 33. — 2020. — Pp. 17022–17033.
- [20] WaveFit: An Iterative and Non-Autoregressive Neural Vocoder Based on Fixed-Point Iteration / Y. Koizumi, K. Yatabe, H. Zen, M. Bacchiani // IEEE Spoken Language Technology Workshop (SLT). — 2023. — Pp. 884–891.
- [21] BigVGAN: A Universal Neural Vocoder with Large-Scale Training / S.-g. Lee, W. Ping, B. Ginsburg et al. // International Conference on Learning Representations (ICLR). — 2023.
- [22] LibriTTS: A Corpus Derived from LibriSpeech for Text-to-Speech / H. Zen, V. Dang, R. Clark et al. // Interspeech. — 2019. — Pp. 1526–1530.
- [23] Valentini-Botinhao, C. Noisy Speech Database for Training Speech Enhancement Algorithms and TTS Models. — University of Edinburgh, Centre for Speech Technology Research (CSTR). — 2017.
- [24] Thiemann, J. The Diverse Environments Multi-channel Acoustic Noise Database (DEMAND) / J. Thiemann, N. Ito, E. Vincent // Proceedings of Meetings on Acoustics. — Vol. 19. — 2013.

- [25] ICASSP 2021 Deep Noise Suppression Challenge / C. K. A. Reddy, H. Dubey, V. Gopal et al. // IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). — 2021. — Pp. 6623–6627.
- [26] w2v-BERT: Combining Contrastive Learning and Masked Language Modeling for Self-Supervised Speech Pre-Training / Y.-A. Chung, Y. Zhang, W. Han et al. // IEEE Automatic Speech Recognition and Understanding Workshop (ASRU). — 2021. — Pp. 244–250.
- [27] Conformer: Convolution-augmented Transformer for Speech Recognition / A. Gulati, J. Qin, C.-C. Chiu et al. // Interspeech. — 2020. — Pp. 5036–5040.
- [28] Park, J. Self-Supervised Representations for Universal Speech Enhancement and Restoration / J. Park, S. Lee, H. Kim // arXiv preprint arXiv:2602.05443. — 2026.

Приложение

Полный перечень гиперпараметров обучения

В табл. 10 приведён полный набор гиперпараметров, при которых получены результаты раздела 5. Конфигурация вокодера HiFi-GAN соответствует варианту V1 из [19] с адаптированным под размерность SSL-признаков входным слоём.

Таблица 10: Полный перечень гиперпараметров

Параметр	Значение
Энкодер	
Скрытая размерность	768
Частота кадров	50 Гц (шаг 20 мс)
Режим	заморожен
Слой извлечения (WavLM / HuBERT)	7 / 6
Очиститель (параллельные адаптеры)	
Размерность узкого места	256
Активация	GELU
Число адаптеров	по числу слоёв энкодера
Функция потерь	$L_1 + L_2$ по признакам, $\lambda = 1$
Вокодер	
Коэффициенты апсемплинга	[8, 8, 2, 2]
Размеры ядер апсемплинга	[16, 16, 4, 4]
Каналы остаточных блоков	512
Число итераций WaveFit	5
Оптимизация	
Оптимизатор	AdamW ($\beta_1 = 0,8$, $\beta_2 = 0,99$)
Начальная скорость обучения	$2 \cdot 10^{-4}$
Затухание скорости	экспоненциальное, $\gamma = 0,999$
Размер батча	16
Длительность сегмента	2 с
Шагов (адаптеры / вокодер)	200 тыс. / 400 тыс.
Аппаратура	1 × NVIDIA RTX 3090, 24 ГБ