

Разработка системы шумоподавления и очистки аудиосигналов на основе глубокого обучения

Вамбриков Никита Сергеевич
МФТИ

Научный руководитель: д-р физ.-мат. наук, проф. Цурков Владимир Иванович

Москва, 2026

Введение

Область и востребованность

Улучшение и восстановление речи требуется в синтезе (TTS) и распознавании (ASR) речи, телефонии, слуховых аппаратах, реставрации архивов и автоматическом создании обучающих датасетов студийного качества.

Цель работы

Построить и исследовать открытую систему восстановления речи на основе архитектуры Miipher-2, заменив недоступный энкодер USM открытыми компонентами.

Существующие подходы

Классические (спектральное вычитание, фильтр Винера); дискриминативные нейросети; генеративные (GAN, диффузия); восстановление через ресинтез (Miipher, Miipher-2).

Основная трудность

Лучшая по качеству модель Miipher-2 опирается на закрытый энкодер USM (2 млрд параметров, 12 млн ч обучения) — веса недоступны, воспроизведение невозможно.

Предлагаемый подход

Заменить USM открытыми SSL-энкодерами (WavLM, HuBERT), исследовать оптимальный слой извлечения признаков и открытые вокодеры (HiFi-GAN, WaveFit).

Анализ базовых источников

Восстановление речи через ресинтез

- Koizumi et al. Miipher (WASPAA 2023); Miipher-2 (arXiv 2025). Недостаток: закрытый энкодер USM; у Miipher-1 — текстовое и дикторское кондиционирование.

Самоконтролируемые энкодеры (SSL)

- HuBERT (2021), WavLM (2022), wav2vec 2.0 (2020). Недостаток: обучены преимущественно на английской речи; разные слои несут разную информацию.

Нейросетевые вокодеры

- HiFi-GAN (2020), WaveFit (2023), BigVGAN (2023). Недостаток: WaveFit итеративен (медленнее в 5 раз), BigVGAN тяжёлый (112 млн параметров).

Классические и дискриминативные методы

- Спектральное вычитание, фильтр Винера, DEMUCS. Недостаток: не восстанавливают подавленные гармоники, вносят музыкальный шум.

Базовая модель: Miipher-2




Рис. 1. Схема восстановления речи в пространстве SSL-признаков

- Очистка выполняется не во временной или спектральной области, а в пространстве признаков SSL-энкодера.
- Схема: SSL-энкодер $\rightarrow$ очиститель признаков $\rightarrow$ нейросетевой вокодер.
- Miipher-2: замороженный USM + параллельные адаптеры (~20 млн) + вокодер WaveFit; без текста и диктора.
- Высокая скорость: RTF $\approx 0,0078$ на TPU; очищено порядка 1 млн ч аудио.

Базовая модель: недостатки

- Закрытый энкодер USM (2 млрд параметров): ни веса, ни обученный очиститель признаков не опубликованы.
- Прямое использование и воспроизведение Miipher-2 в открытых проектах невозможно.
- Miipher-1 дополнительно требует текстовой расшифровки и идентификатора диктора на входе.
- Реализация ориентирована на ускорители TPU — высокий порог входа.

Вывод: необходима открытая замена энкодера и подбор открытого декодера, что и является задачей работы.

Формальная постановка и обозначения

Дан искажённый сигнал y (шум, реверберация, кодек). Модель искажения:

$$y(t) = \mathcal{C}((x * h)(t) + n(t))$$

где h — импульсная характеристика помещения, n — шум, $\mathcal{C}$ — искажения тракта и кодека; уровень шума:

$$\text{SNR} = 10 \lg \frac{\sum_t ((x * h)(t))^2}{\sum_t n^2(t)} \quad [\text{дБ}]$$

Требуется восстановить оценку чистого сигнала. Обозначения признаков:

$$z = E(y), \quad z^* = E(x), \quad \hat{z} = G_\phi(z), \quad \hat{x} = V_\psi(\hat{z})$$

Критерии качества решения

- PESQ — перцептивное качество (от -0,5 до 4,5), интрузивная метрика.
- STOI — разборчивость речи (от 0 до 1), интрузивная.
- SI-SDR — масштабно-инвариантное отношение сигнал/искажение, дБ:

$$\text{SI-SDR} = 10 \lg \frac{\|\alpha x\|^2}{\|\alpha x - \hat{x}\|^2}, \quad \alpha = \frac{\langle \hat{x}, x \rangle}{\|x\|^2}$$

- DNSMOS — неинтрузивная нейросетевая оценка качества (без эталона).
- RTF — коэффициент реального времени (быстродействие).

Требования: прирост PESQ $\geq 0,6$ и STOI $\geq 0,05$; RTF < 1 ; обучаемых параметров $\leq \sim 15$ млн.

Предлагаемый метод: архитектура




Рис. 2. Параллельные адаптеры в замороженном энкодере; слой $\ell \rightarrow$ вокодер

Замороженный открытый SSL-энкодер + обучаемые параллельные адаптеры (очиститель) + открытый вокодер. Признаки выбранного слоя ℓ подаются на вокодер.

Предлагаемый метод: очиститель признаков

Очиститель — параллельные адаптеры с остаточной связью, встроенные в слои энкодера:

$$\tilde{h}^{(i)} = h^{(i)} + W_{\text{up}} \sigma(W_{\text{down}} h^{(i)})$$

- Скрытая размерность узкого места 256, активация GELU; добавляет ~4,9 млн обучаемых параметров.
- Энкодер заморожен — обучаются только адаптеры и декодер.

Функция потерь очистителя (рассогласование признаков, $\lambda = 1$):

$$\mathcal{L}_{\text{fc}}(\phi) = \|G_{\phi}(E(y)) - E(x)\|_1 + \lambda \|G_{\phi}(E(y)) - E(x)\|_2^2$$

Целевые признаки z^ получаются прогоном чистого сигнала через тот же замороженный энкодер.*

Предлагаемый метод: выбор энкодеров

Замена закрытого USM двумя открытыми SSL-энкодерами с близкой структурой:

Энкодер	Параметры	Слоёв	Данные предобуч.	Особенность
WavLM Base+	95 млн	12	94 тыс. ч	денойзинг при предобучении
HuBERT Base	95 млн	12	960 ч	предсказание кластеров
USM (закрыт)	2 млрд	32	12 млн ч	BEST-RQ, 300+ языков

Гипотеза: благодаря моделированию шума при предобучении представления WavLM устойчивее к деградациям, чем у HuBERT.

Оба энкодера: скрытая размерность 768, частота кадров 50 Гц (шаг 20 мс); используются в замороженном виде.

Исследование слоя извлечения признаков




Рис. 3. Зависимость качества (PESQ) от номера слоя извлечения признаков

- Качество немонотонно зависит от слоя; максимум — на средних слоях.
- Оптимум: $\ell = 7$ (WavLM), $\ell = 6$ (HuBERT).
- Сопласуется с SUPERB и с 13-м слоем USM (средняя треть сети).

Предлагаемый метод: вокодер и конфигурации

Вокодер обучается в генеративно-состязательном режиме ($\lambda_{\text{fm}} = 2$, $\lambda_{\text{mel}} = 45$):

$$\mathcal{L}_V = \mathcal{L}_{\text{adv}}(V_\psi) + \lambda_{\text{fm}} \mathcal{L}_{\text{fm}} + \lambda_{\text{mel}} \mathcal{L}_{\text{mel}}$$

- HiFi-GAN — однопроходный, быстрый; WaveFit — итеративный (5 итераций), естественнее.

Два энкодера × два вокодера = четыре исследуемые конфигурации:

Обозн.	Энкодер	Вокодер	Комментарий
K1	HuBERT Base	HiFi-GAN	базовая быстрая конфигурация
K2	HuBERT Base	WaveFit	итеративный вокодер
K3	WavLM Base+	HiFi-GAN	устойчивый энкодер + быстрый вокодер
K4	WavLM Base+	WaveFit	наиболее близка к Miipher-2

Параметры вычислительного эксперимента

Данные и гиперобучение

Выборка	Источник	Объём	Назначение
Обучающая	LibriTTS train	240 ч	обучение адаптеров и вокодера
Валидационная	LibriTTS dev	12 ч	подбор слоя и гиперпараметров
Тест А	VCTK	8 ч	невиданные дикторы
Тест В	LibriTTS test-clean	10 ч	сравнение результатов

Гиперпараметр	Значение
Оптимизатор	AdamW
Learning rate	$2 \cdot 10^{-4}$
Batch size	16
Сегмент / fs	2 с / 16 кГц
Шаги (адапт./вок.)	200к / 400к
GPU	RTX 3090, 24 ГБ

Деградации: шум (DEMAND, DNS Challenge), реверберация (RIR), сжатие кодеками; SNR $\in [0; 20]$ дБ. Смесь формируется по правилу:

$$y_0 = (x * h) + g \cdot n, \quad g = \sqrt{\frac{\|x * h\|^2}{\|n\|^2} \cdot 10^{-\text{SNR}/10}}$$

Результаты: сравнение качества

Конфигурация	PESQ ↑	STOI ↑	SI-SDR, дБ ↑	DNSMOS ↑
Вход (шум)	1,82	0,841	4,7	2,41
K1 (HuBERT+HiFi-GAN)	2,71	0,908	13,9	3,18
K2 (HuBERT+WaveFit)	2,78	0,912	14,3	3,29
K3 (WavLM+HiFi-GAN)	2,94	0,927	15,2	3,41
K4 (WavLM+WaveFit)	2,97	0,929	15,6	3,52




Рис. 4. Качество — быстродействие

- Все конфигурации дают прирост PESQ на 0,9–1,15 и STOI на 0,07–0,09 — выше целевых ориентиров.
- Замена HuBERT → WavLM устойчиво улучшает все метрики; тип вокодера влияет на качество слабее.

Сравнение с базовыми методами и анализ

Метод	PESQ ↑	STOI ↑	SI-SDR ↑	DNSMOS ↑
Вход (шум)	1,82	0,841	4,7	2,41
Винеровская фильтрация	2,11	0,868	9,8	2,67
DEMUCS	2,64	0,915	16,1	3,12
КЗ (наш подход)	2,94	0,927	15,2	3,41

Анализ и выводы о гипотезе

- Классический фильтр не восстанавливает структуру сигнала; DEMUCS выше по SI-SDR, но уступает по перцептивным PESQ/DNSMOS (нет ресинтеза).
- Конфигурации с HiFi-GAN $\approx$ в 4,4 раза быстрее аналогов с WaveFit при близком качестве.
- Гипотеза подтверждена: открытые SSL-энкодеры заменяют USM; решающую роль играют выбор энкодера и слоя, а не вокодера.

Заключение

Основной результат

- Открытая система восстановления речи на базе Miipher-2. Лучшая конфигурация — WavLM Base+ + HiFi-GAN (слой 7): PESQ 2,94; STOI 0,927; SI-SDR 15,2 дБ; DNSMOS 3,41; RTF 0,034.

Поставленная задача решена

- Все целевые метрики качества и быстродействия превышены; найдена конфигурация с наилучшим балансом.

Научная новизна

- Систематически исследовано влияние открытого SSL-энкодера и слоя извлечения признаков на качество восстановления в схеме Miipher-2.

Практическая значимость

- Автоматическое создание обучающих датасетов студийного качества из полностью открытых компонентов.

Планы на следующий этап

- WavLM Large и анализ его слоёв; сквозное (end-to-end) дообучение; многоязычные данные; субъективная оценка MOS.

Список использованных источников

1. Koizumi Y. et al. *Miipher-2: A Universal Speech Restoration Model for Million-Hour Scale Data Restoration* // arXiv:2505.04457. — 2025.
2. Koizumi Y. et al. *Miipher: A Robust Speech Restoration Model Integrating Self-Supervised Speech and Text Representations* // WASPAA. — 2023.
3. Hsu W.-N. et al. *HuBERT: Self-Supervised Speech Representation Learning by Masked Prediction of Hidden Units* // IEEE/ACM TASLP. — 2021.
4. Chen S. et al. *WavLM: Large-Scale Self-Supervised Pre-Training for Full Stack Speech Processing* // IEEE JSTSP. — 2022.
5. Kong J., Kim J., Bae J. *HiFi-GAN: GANs for Efficient and High Fidelity Speech Synthesis* // NeurIPS. — 2020.
6. Koizumi Y. et al. *WaveFit: An Iterative and Non-Autoregressive Neural Vocoder* // IEEE SLT. — 2023.
7. Baevski A. et al. *wav2vec 2.0: A Framework for Self-Supervised Learning of Speech Representations* // NeurIPS. — 2020.
8. Zhang Y. et al. *Google USM: Scaling Automatic Speech Recognition Beyond 100 Languages* // arXiv:2303.01037. — 2023.